

~~Max~~ $\text{Attack}(\theta, D_{\text{test}})$
 D_{poison}

(1) ان

$$\text{s.t. } \theta = \arg \min_{\theta'} \ell_{\text{train}}(\theta', D_{\text{train}} + D_{\text{poison}})$$

حمیدرضا اسیرزاده یعنی D_{poison} با عمل کردن مستند بهینه سازی در سطحی بالا به دست می آید

ب) مثالی درش ارائه شده این است که تابع هشی داده شده دارد ما را به صورت یک دسته نکات

می کند و در واقع همبستگی داده ها پس از تقسیم بندی آن ها وجود دارد به عبارت دیگر اگر $h(s)$

اعدادی غیر از اعداد اول تولید کند، باز باشد $h(s)$ به میں از یک دسته i معرفی شود و در نتیجه

این داده به چندی دسته تعلق خواهد گرفت. با قدم به این نکته می توان تقصیری با قدم به این روش

ارائه داده زیرا اگر یک نمونه فقط به یکی از K دسته تعلق داشته باشد باعث می شود که نتیجه حد اکثر یکی از

دسته به ما معرفی شود. و این بدان این تقسیم بندی می توان به صورت زیر عمل کرد:

$$P_i^s = \{s \in S \mid h(s) = K \bmod i\}$$

همچنین تدبیر کرد که باید راهکاری برای حالتی که بین از یک دسته مشترکاً تعداد زیادی یکسانی دارند ارائه

محال (به عنوان مثال انتخاب دسته با کمترین اعداد) که در اینجا ارائه شده است.



دوشنبه

Monday

29 May 2023

۹ ذی القعدة ۱۴۴۴

فرداد

۵ الف) از آجایی که در این الگوریتم، کلاس هدف مشخص نشده است و به عنوان ورودی

داده شده است. بنابراین مدای $untargeted$ و $targeted$ برای هدفمند کردن آن

کاربران است در خط زری را تغییر دهیم:

$$4 \text{ while } P_y = \max_y P_{y'} \Rightarrow \text{while } P_t \neq \max_{y'} P_{y'}$$

$$8 \text{ if } P_{y'} < P_y \Rightarrow \text{if } P_{t'} > P_t$$

ب) دلیل انتخاب بردارهای $orthonormal$ آن است که تغییرات در فضای از جهت ها توسط برداری از

جهت یکی فضای شود. همچنین از اینکه در مبنی بین از ج حرکت کنیم عبور می رو کند، زیرا با انتخاب

این بردارها بدون وابستگی است، بنابراین L_{∞} آشفتگی از ج فراتر نمی رود.

ج) در این الگوریتم بردار P_t که اگر مقدار $P_{y'}$ از یک آستانه یعنی $P_{y'}$ از این دانه

بزرگ آنگاه می توان اینطور بردار P_t که اگر در جهت مخالف حرکت کنیم، امکان گشته شد. که مبنی

خطا می یافت. بنابراین می توان از این تکنیک به عنوان یک $heuristic$ برای کاهش تعداد گزری ما

استاده کرد.

$$\begin{aligned} q_t^T \cdot q_t &= 0 \Rightarrow \| \delta_T \|^2 = \left\| \sum_{t=1}^T \alpha_t q_t \right\|_2^2 = \sum_{t=1}^T \alpha_t^2 \| q_t \|^2 \\ &= \sum_{t=1}^T \alpha_t^2 \| q_t \|^2 \leq T \epsilon^2 \Rightarrow \| \delta_T \|_2 \leq \sqrt{T} \epsilon \end{aligned} \quad (d)$$

و تئوری که روی تعداد گزری ها محدودیت وجود دارد، برای از این $distance$ ها نیاز است که ج مقدار

بزرگتری انتخاب کنیم. اما اگر فرض کنیم ϵ ها کم باشند و α ها حفظ شود، باید تعداد گزری ها از این باید

که در نتیجه آن T از این باید. بنابراین یک معادله بین تعداد گزری و میزان آشفتگی وجود دارد.

(۳) الف) مایه علامت گرایان به صورتی باشد که علامت گرایان درجهتی که و از این

می باشد یک باشد و درجهتی که و گامش مایه 1-


مایه می شکل زدی توان دریافت که جابجایی درجهت مایه به مرتز تقیم گیری

نزدیک شده و در نتیجه مقدار و گامش مایه یکی جابجایی درجهت مایه از مرتز تقیم گیری دور

شده و مقدار و از این مایه بنیاد این علامت گرایان درجهت مایه یار 1 و درجهت

مایه یار 1- مکن

$$\operatorname{sgn} g(\theta + \epsilon u) - g(\theta) = \begin{cases} +1 & : f(x+g(\theta) \frac{\theta + \epsilon u}{\|\theta + \epsilon u\|}) = \gamma \\ -1 & : 0. \end{cases}$$



ب) اگر نتواند از علامت گرایان استفاده کنیم، نیاز به تعداد کوچکی مای بیتری برای تخمین

گرایان داریم زیرا علامت گرایان بست به قدر گرایان اطلاعات کمتری دارد.

اما به هر حال جای تری عدد مای فضا نه، استفاده از علامت گرایان نیز گنایت و کند.

(۴) Time dependant prior: می‌توان نشان داد گرایان‌های که از طریق

روش NES در هر step از جمله PGD محاسبه می‌شوند، همبستگی یا correlation

بسیار زیادی با هم دارند. در واقع Cosine similarity گرایان‌های متوالی حدود ۰.۹

است که خاصه این مدیات. برای استفاده از این خاصه، در این مقاله از گرایان تخمینی در مرحله t

به عنوان یک prior برای گرایان مرحله t استفاده می‌شود.

Data dependant prior: از آنجایی که در داده‌ها همبستگی، مشابهت محلی یا spatial local similarity

(پیکسل‌های که از نقاط مجاور نزدیک هم هستند، مقدار مشابهی دارند) به نیاوران این مشابهت در گرایان ما

باز وجود دارد. به طوری که تغییر هرگاه در محله (زاویه) (θ, ϕ) در داده ورودی به نزدیک و مشابه باشند

است. $\nabla_{\theta} L(x, y)$ به $\nabla_{\phi} L(x, y)$ برای استفاده از این خاصه، در این مقاله تقسیم $\nabla_{\theta} L(x, y)$

که می‌شود با σ است را با یک کرنل (K, K) و استرایپ (K, K) Average Pooling می‌گیرد

تا به این ترتیب اندازه سنده با ضرب K^2 که یک عدد در نهایت به صورت مسکوس سنده $upscale$ می‌شود و در نهایت اصلی می‌گردد.

ب) اگر نزدیک کنیم $\langle \nabla_{\theta} L(x, y), \nabla_{\phi} L(x, y) \rangle = l_t(\gamma)$ آنگاه ردیفی که برای تخمین گرایان این تابع که با Δ_t

نمایان داده می‌شود، استفاده از $spherical gradient estimator$ می‌شود. به این صورت که از دو کوئرتی ورودی

جهت نشان u که به صورت نمونه برداری می‌شوند. antithetic sampling انتخاب می‌شوند به طوری که:

$$\Delta_t \approx \frac{l_t(\gamma + \delta u) - l_t(\gamma - \delta u)}{\delta} u \quad ; \quad u \sim \mathcal{N}(0, \frac{1}{\delta} I)$$

وای $q_1 = \gamma + \delta u$ و $q_2 = \gamma - \delta u$ پس تابع لاس l_t را در نقاط q_1 و q_2 به صورت

$$\begin{cases} l_t(q_1) = \langle \nabla L(x, y), q_1 \rangle \approx \frac{L(x, y) - L(x + \epsilon q_1, y)}{\epsilon} \\ l_t(q_2) = \langle \nabla L(x, y), q_2 \rangle \approx \frac{L(x, y) - L(x + \epsilon q_2, y)}{\epsilon} \end{cases}$$

در تخمین بالا از منجم مشتق محلی $l_t(x, y)$ ما در نهایت q استفاده می‌کنیم. در نهایت Δ_t به صورت زیر محاسبه می‌شود:

$$\Delta_t = \frac{l_t(q_1) - l_t(q_2)}{\delta} u = \frac{L(x + \epsilon q_2, y) - L(x + \epsilon q_1, y)}{\delta}$$