

(۲) این بیان داده نام کلاس اول رابطه مقابل را داریم:

$$z_i^{(1)} = w_i^T h^{(1)} + b_i$$

از آنجایی که این یک معادله خطی می باشد که $n+1$ مجهول دارد. بنابراین اگر $n+1$ بردار h مستقل خطی داشته باشیم، می توان معادله زیر را حل کرد:

$$\begin{bmatrix} z_1^{(1)} \\ \vdots \\ z_{n+1}^{(1)} \end{bmatrix} = \begin{bmatrix} h^{(1)} \\ \vdots \\ h^{(n+1)} \end{bmatrix} w_i + \begin{bmatrix} b_i \\ \vdots \\ b_i \end{bmatrix}$$

بنابراین مطابق این روش می توان وزن های رگرسیون جمعیت را بازی کرد.

ج) از آنجایی که فضای مجهول ها $n+1$ بعدی است بنابراین اگر تعداد داده بیشتر در نظر گرفته شود، مثلاً از داده $n+2$ به بعد را می توان به صورت ترکیب خطی $n+1$ داده اول به دست آورد. بنابراین اطلاعات جدیدی به دست نمی آید.

ج) P_j را هر بار افعال داریم

$$P_j = \frac{\exp(z_j)}{\sum_{k=1}^L \exp(z_k)}$$


حال می توان یکی از افعال سری فرجه را افعال پایه در نظر گرفت و مرکز از سایر افعال (ها) و آن تقسیم کرد پس

نگاه کنیم:

$$\log \frac{P_j}{P_i} = \log \frac{\exp(z_j)}{\exp(z_i)} = z_j - z_i = (w_j - w_i)h + b_j - b_i$$

در اینجا نیز $w_j - w_i$ ، n عنصر دارد. یک بایاس داریم بنابراین اگر فرض کنیم فرجه های شبکه خطی مستقل فعلی باشند نیاز به n داده داریم که بتوان n معادله برای $n+1$ مجهول را تشکیل دهیم و شباهت های آن شده را طاق کنیم. اگر از بیشتر از n داده استفاده کنیم فایده ای ندارد زیرا می توان یکی از داده ها را به صورت سایر داده ها نوشت و وزن های که از عمل این معادلات به دست می آید جایز است با $w_j - w_i$ که از یک وزن ثابت است و نه باید از K قفسه کند. برای بایاس نیز داریم $b_j - b_i$

(۳) مثال زیر را در نظر بگیرید:



$$S_{p+1} = \{x + \lambda_{p+1} \text{sgn}(J_F[\tilde{O}(x)]) : x \in S_p\} \cup S$$

افزودن را انجام دهیم، داده های جدید به طریقی ساخته می شوند که از

مرز Oracle فاصله بیشتری بگیرند و در واقع بینشی Oracle روی

آنها اطمینان بیشتری یابد. واضح است که اگر مدل جایگزین را روی چنین نمونه هایی آموزش دهیم، گاهی به

تضادیک کردن مرز **مدله** جایگزین به مرز Oracle می کنند.

$$S_{p+1} = \{x - \lambda_{p+1} \text{sgn}(J_F[\tilde{F}(x)]) : x \in S_p\} \cup S$$

طریقی ساخته می شوند که به مرز مدل جایگزین نزدیک شوند. در واقع مثل این است که برای مدل جایگزین نمونه ضعیفانه

تولید کرده ایم. در این روش تقابلی وجود ندارد که با آموزشی مدل روی چنین نمونه داده های، مرز

مدل جایگزین به مرز Oracle نزدیک شود، زیرا لزوماً به مرز Oracle نزدیک نمی شویم.

$$S_{p+1} = \{x - \lambda_{p+1} \text{sgn}(J_F[\tilde{O}(x)]) : x \in S_p\} \cup S$$

به طریقی ساخته می شوند که به مرز Oracle نزدیک شوند. بنابراین با آموزشی مدل جایگزین روی چنین نمونه داده ای

می توان مرز مدل جایگزین را به مرز Oracle نزدیک کرد، که این هدف اصلی ما است.

(۴) با اینکه ϵ -DP تعیین کند باید تابع هزینه P_{valid} در تمام نقاط نزدیک باشد، نه بی نهایت میل نکند. اما وقتی به دست در توزیع احتمال برای دو دیتا x و y که $\|x - y\|$ کمترین باشد، در حالتی که داده ها متنوع در این دو دیتا برای یکی مقدار ۱ و برای دیگری صفر باشد، به عنوان مثال

$$f(x) = p(y) + 1 \quad x_i = 1, y_i = 0 \text{ داریم}$$

حال در صورت ϵ DP برای نرم $\frac{P_x(z)}{P_y(z)}$ چون $f(x) = p(y)$ بنابراین میانگین نرم $P_x(z)$ و $P_y(z)$ مقادیر است در فضای خارج از بازه $[f(y) - \epsilon/2, f(x) + \epsilon/2]$ که $P_y(z)$ برای مقادیر $P_x(z)$ مقدار $\epsilon/2$ دارد بنابراین $\frac{P_x(z)}{P_y(z)}$ در تمامی برای بی نهایت میل کند، بنابراین عملاً مرزی در آن نقطه برای ϵ -DP بدون نداریم، بنابراین \bar{f} به صورت $DP - O(\epsilon)$ است.

در بازه ای که هیچ کدام از $P_x(z)$ و $P_y(z)$ برای صفر نیستند ~~داریم~~ داریم،

$$\frac{P_x(z)}{P_y(z)} = \frac{\frac{1}{f(x) - \epsilon/2 - f(y) + \epsilon/2}}{\frac{1}{f(y) + \epsilon/2 - f(x) + \epsilon/2}} = \frac{1/\epsilon/2}{1/\epsilon/2} = 1 = \exp(0)$$

بنابراین در این بازه $DP - O(\epsilon)$ است اما ϵ به صورت $O(\frac{1}{\epsilon/2})$ میل کند. مطلب این است که ϵ کوچک تر شود بنابراین باید ϵ را که بیک در نظر گرفت که این منجر به بیشترین بازه $[\epsilon/2 - \epsilon/2, \epsilon/2 + \epsilon/2]$ را که ضد صحت گمن $accuracy$ را کند.

$$\text{Lip}_{1, d_{ham}}(\hat{P}_n) = \sup \{ \|\hat{P}_n(x_i^n) - \hat{P}_n(y_i^n)\|_1 \mid d_{ham}(x_i^n, y_i^n) \leq 1 \} \quad (8)$$

$$x_i^n = \begin{bmatrix} x_1 \\ x_r \\ \vdots \\ x_j \\ \vdots \\ x_n \end{bmatrix}_{n \times 1}$$

$$\hat{P}(x_i^n) = \begin{bmatrix} \frac{1}{n} \sum_{i=1}^n 1\{x_i = 1\} \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n 1\{x_i = K\} \end{bmatrix}_{K \times 1}$$

$$y_i^n = \begin{bmatrix} y_1 \\ y_r \\ \vdots \\ y_j \\ \vdots \\ y_n \end{bmatrix}_{n \times 1}$$

$$\hat{P}(y_i^n) = \begin{bmatrix} \frac{1}{n} \sum_{i=1}^n 1\{y_i = 1\} \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n 1\{y_i = K\} \end{bmatrix}_{K \times 1}$$

از آنجایی که $d_{ham}(x_i^n, y_i^n) \leq 1$ بنابراین تمامی درایه های آن ما به جز حد اکثر یکی با هم برابرند.

زیرا کنیم درایه j ام آنها متفاوت باشد: $x_j \neq y_j$ ، $x_i = y_i$: $i \neq j$

$$\hat{P}(x_i^n) = \begin{bmatrix} p_1 \\ p_r \\ \vdots \\ p_{x_j} \\ \vdots \\ p_K \end{bmatrix}_{K \times 1}$$

زیرا کنیم $\hat{P}(x_i^n)$ را به صورت زیر محاسبه کرده باشیم:

از آنجایی که تفاوت x_i^n و y_i^n در درایه j ام آنهاست بنابراین،

$\hat{P}(y_i^n)$ دقیقاً مشابه $\hat{P}(x_i^n)$ است با این تفاوت که در

از امتلا است x_j ، $\frac{1}{n}$ کاسته و به امتلا است y_j ، $\frac{1}{n}$

افزوده می شود:

$$\hat{P}(y_i^n) = \begin{bmatrix} p_1 \\ p_r \\ \vdots \\ p_{x_j} - \frac{1}{n} \\ \vdots \\ p_{y_j} + \frac{1}{n} \\ \vdots \\ p_K \end{bmatrix}_{K \times 1}$$

$$\Rightarrow \sup (\|\hat{P}_n(x_i^n) - \hat{P}_n(y_i^n)\|_1) = 2/n$$

$$E[\|z - p\|_r^r] = E\left[\sum_{i=1}^K (z_i - p_i)^r\right]$$

$$= E\left[\sum_i (\hat{p}_{n,i} + w_i - p_i)^r\right] = \sum_i E\left[(\hat{p}_{n,i} - p_i + w_i)^r\right]$$

$$= \sum_i E\left[w_i^r + (\hat{p}_{n,i} - p_i)^r + r w_i (\hat{p}_{n,i} - p_i)\right]$$

$$= \sum_i \left[E[w_i^r] + E[(\hat{p}_{n,i} - p_i)^r] + r E[w_i] + (E[\hat{p}_{n,i}] - p_i) \right]$$

$$= \sum_i \left[E[w_i^r] + E[\hat{p}_{n,i}^r + p_i^r - r \hat{p}_{n,i} p_i] \right]$$

$$= \sum_i \left[E[w_i^r] + E[\hat{p}_{n,i}^r] + p_i^r - r p_i E[\hat{p}_{n,i}] \right]$$

$$= \sum_i \left[E[w_i^r] + E[\hat{p}_{n,i}^r] - p_i^r \right] = \sum_i \left[E[w_i^r] + \text{Var}[\hat{p}_{n,i}] \right]$$

$$\text{Var}(K_i) = n p_i (1 - p_i) \quad \hat{p}_{n,i} = \frac{K_i}{n} \Rightarrow \text{Var}[\hat{p}_{n,i}] = \frac{1}{n^r} \text{Var}[K_i] = \frac{1}{n} p_i (1 - p_i)$$

$$\text{Var}[w_i] = r \left(\frac{\sum}{n \epsilon} \right)^r = \frac{\Lambda}{n^r \epsilon^r} = E[w_i^r] - E[w_i]^r$$

$$\rightarrow E[\|z - p\|_r^r] = \sum_{i=1}^K \left[\frac{\Lambda}{n^r \epsilon^r} + \frac{1}{n} p_i (1 - p_i) \right]$$

$$= \frac{\Lambda K}{n^r \epsilon^r} + \frac{1}{n} \sum_{i=1}^K p_i (1 - p_i)$$

$$\sum_{i=1}^K p_i (1 - p_i) = \sum_{i=1}^K p_i - \sum_{i=1}^K p_i^r = 1 - \sum_{i=1}^K p_i^r \leq 1$$

$$\Rightarrow E[\|z - p\|_r^r] \leq \frac{\Lambda K}{n^r \epsilon^r} + \frac{1}{n}$$

$$X_i = \begin{cases} 1 & : P \\ 0 & : 1-P \end{cases} \quad E[X] = P(X_i=1) = P \quad \text{برندی} \quad \textcircled{۷} \text{ اگر فرض کنیم که}$$

$$Y_i = \begin{cases} X_i & : \frac{1}{r} + \alpha \\ 1-X_i & : \frac{1}{r} - \alpha \end{cases} \quad E[Y] = P(Y_i=1) \quad \text{برندی} \quad \text{آنگاه داریم:}$$

$$P(Y_i=1) = P(Y_i=1 | X_i=1) P(X_i=1) + P(Y_i=1 | X_i=0) P(X_i=0) \\ = \left(\frac{1}{r} + \alpha\right) P + \left(\frac{1}{r} - \alpha\right) (1-P) = 2\alpha P + \frac{1}{r} - \alpha$$

$$\Rightarrow P = \frac{E[Y] + \alpha - \frac{1}{r}}{2\alpha} \quad \text{استفاده از تخمینگر ناریب برای برآورد} \quad \hat{P} = \frac{\sum_{i=1}^n \frac{Y_i}{n} + \alpha - \frac{1}{r}}{2\alpha}$$

$$E[\hat{P}] = \frac{\frac{1}{n} E\left(\sum_{i=1}^n Y_i\right) + \alpha - \frac{1}{r}}{2\alpha} = \frac{E[Y] + \alpha - \frac{1}{r}}{2\alpha} = P$$

بنابراین \hat{P} یک تخمینگر ناریب برای P است.

$$\text{Privacy loss} = \log\left(\frac{P(Y_i=1 | X_i=1)}{P(Y_i=1 | X_i=0)}\right) = \log\left(\frac{\frac{1}{r} + \alpha}{\frac{1}{r} - \alpha}\right) \quad \text{ب)}$$

$$\alpha = 0 : P.\text{loss} = \log 1 = 0 \quad \Rightarrow \quad \text{ODP است و هیچ اطلاعاتی نت پیدا نمی کند}$$

$$\alpha = \frac{1}{r} : P.\text{loss} = \log \infty = \infty \quad \Rightarrow \quad \text{هیچ فریم خصوصی وجود ندارد و همه اطلاعات نت پیدا می کنند}$$

برای بردن آلودگی دیت تخمینگر، از آنبایس که bias داریم، فقط به حساب داریم آن می پردازیم:

$$\text{Var}(\hat{P}) = \text{Var}\left(\frac{\sum_{i=1}^n \frac{Y_i}{n} + \alpha - \frac{1}{r}}{2\alpha}\right) = \frac{1}{4\alpha^2} \text{Var}\left(\sum_{i=1}^n \frac{Y_i}{n}\right) = \frac{1}{4\alpha^2 n} \text{Var}(Y_i)$$

$$\text{Var}(Y_i) = E[Y_i^2] - E^2[Y_i] \quad , \quad E[Y_i^2] = E[Y_i]$$

$$\Rightarrow \text{Var}(Y_i) = E[Y_i] - E^2[Y_i] = 2\alpha P + \frac{1}{r} - \alpha - \left(2\alpha P + \frac{1}{r} - \alpha\right)^2 \\ = \frac{1}{r} - 4\alpha^2 P^2 + 4\alpha^2 P - \alpha^2$$

$$\text{بنابراین} \quad \Rightarrow \text{Var}(\hat{P}) = \frac{1}{n} \left(\frac{1}{4\alpha^2} - P^2 + P - \frac{1}{r} \right)$$

$$\alpha = 0 : \text{var}(\hat{p}) = \infty$$

$$\alpha = 1/2 : \text{var}(\hat{p}) = \frac{p(1-p)}{n}$$

توجه شود که $p(1-p)$ برابر $\text{var}(x_i)$ می باشد. بنابراین در حالت $\alpha = 1/2$: $\text{var}(y_i) = \text{var}(x_i)$

ج) با داشتن تاسی چیهیف و \hat{p} داریم:

$$\Pr[|\hat{p} - E[\hat{p}]| \geq \epsilon] \leq \frac{\text{var}(\hat{p})}{\epsilon^2}$$

$$\Rightarrow \Pr[|\hat{p} - p| \geq \epsilon] \leq \frac{1}{n\epsilon^2} \left[\frac{1}{4\alpha^2} - \frac{1}{\epsilon} + p - p^2 \right]$$

برای آنکه ضرایب تخمین از ϵ که بکتر باشد یعنی $|\hat{p} - p| < \epsilon$ باید عبارت $1 - \frac{1}{n\epsilon^2} \left[\frac{1}{4\alpha^2} - \frac{1}{\epsilon} + p - p^2 \right]$

همچنین نزدیک شود که با افزایش n به اندازه کافی به این حد نزدیک و نزدیک تر شویم.